

深度卷积网络压缩算法在焊缝识别中的应用

刘美菊, 运勃*

沈阳建筑大学信息与工程学院, 辽宁 沈阳 110168

摘要 传统图像识别算法识别模型单一且易受外部光照条件干扰,深度卷积网络模型虽然识别率高,但计算量大,设备成本高,因此提出基于深度同或卷积网络的改进型压缩算法。首先介绍了焊缝识别系统的组成和经典卷积神经网络模型,然后阐述了改进型的卷积网络压缩算法,包括权值更新算法和权值补偿算法,最后在自制数据集和仿真平台上进行了数据实验。研究结果表明,所提算法具有识别率高、模型小、适应性强和识别模型多样化的优点,可应用于焊接现场对焊缝中心的识别。

关键词 图像处理; 深度学习; 卷积压缩算法; 同或卷积网络; 焊缝识别

中图分类号 TP183

文献标识码 A

doi: 10.3788/LOP56.051004

Application of Deep Convolution Network Compression Algorithm in Weld Recognition

Liu Meiju, Yun Bo*

Information & Control Engineering Faculty, Shenyang Jianzhu University, Shenyang, Liaoning 110168, China

Abstract The traditional image recognition algorithm has only a single recognition model and is susceptible to the external illumination interference. In contrast, as for the deep convolutional network model, there exist a large amount of calculation and high cost although its recognition rate is high. An improved based compression algorithm is proposed based on the deep XNOR-network. The compositions of the weld recognition system and the classical convolution neural network model are first introduced. The improved convolution network compression algorithm is described, including the weight update algorithm and the weight compensation algorithm. The data experiments are performed on the self-made datasets and the simulation platform. The research results show that the proposed algorithm has the advantages of high recognition rate, small model, strong adaptability and diversity of recognition models, which can be applied to the weld identification in the welding site.

Key words image processing; deep-learning; convolutional compression algorithm; XNOR network; weld recognition

OCIS codes 100.4999; 100.4996; 150.1135

1 引言

在焊接领域,焊缝中心的识别是关键问题。20 世纪 70 年代出现的夹具方法具有模型易损耗、做工粗糙、定位不准等问题。20 世纪 90 年代初尝试采用超声波接收器等技术方案,但由于干扰因素较多并未得到进一步发展。近年来,随着计算机视觉技术和结构光技术的兴起,当前对焊接设备的识别多采用采集图像后配合如 Lowe^[1] 提出的尺度不变特

征变换(SIFT)特征点监测方法或 Harries 角点检测算法^[2]来提取特征点,再依据已有经验和工件几何关系设计算法。但此类算法泛化能力差,且易受干扰,对现场实际环境的要求很高。

随着深度学习技术的崛起,以 Krizhevsky 等^[3]提出的 Alex-Networks、牛津大学视觉研究组提出的 Vgg-net^[4]等深度卷积神经网络为代表的模型采用类似生物神经系统的权值共享方法。周志华^[5]认为深度神经网络输入特性简洁,非线性表征能力强。

收稿日期: 2018-08-23; 修回日期: 2018-09-14; 录用日期: 2018-09-26

基金项目: 辽宁省科学技术厅项目(201602616)

* E-mail: 1287724534@qq.com

由此分析可知,深度学习技术适合应用于焊缝的检测和识别。

然而,深度卷积网络计算量复杂、生成模型巨大的特点使得深度学习模型的使用范围受限于硬件设备。现场应用该类模型需要昂贵的设备,且灵活性低。因此,压缩深度卷积网络的计算量与存储空间成为难点和目标。Han 等^[6]采用剪枝、聚类算法和霍夫曼编码的形式压缩模型的存储空间。Hubara 等^[7]提出的二值神经网络(BNN)方法是一种将权值进行二值化的方法,采用量化的方法提高了网络的推断速度。Rastegari 等^[8]提出的二值权重网络(BWN)算法针对二值化网络训练困难的问题提出了一种宽松化梯度的训练方法。

本文分析了焊缝识别系统的基本工作原理及深度卷积网络模型,并提出一种改进的压缩算法压缩

训练完成的模型。采用该模型在自制数据集上进行训练与测试实验。由实验结果分析可知,该方法可以准确确定焊缝中心。

2 基本原理

2.1 焊缝检测系统及图像预处理

焊缝识别系统结构如图 1 所示,通过视觉传感器将图像传递至上位机或计算单元,经预处理并利用图像处理算法进行分析。将识别出的 V 型焊缝中心点坐标转换为三维坐标并发送至控制器,控制器调动驱动系统驱动电机和焊机对焊接件进行焊接,最终完成焊接任务^[9]。樊德金等^[10]采用最小二乘法对焊缝进行拟合。周红明等^[11]分析了 Hough 变换法识别焊缝的性能。许皓^[12]采用 SIFT 特征点提取方法对焊缝进行识别。

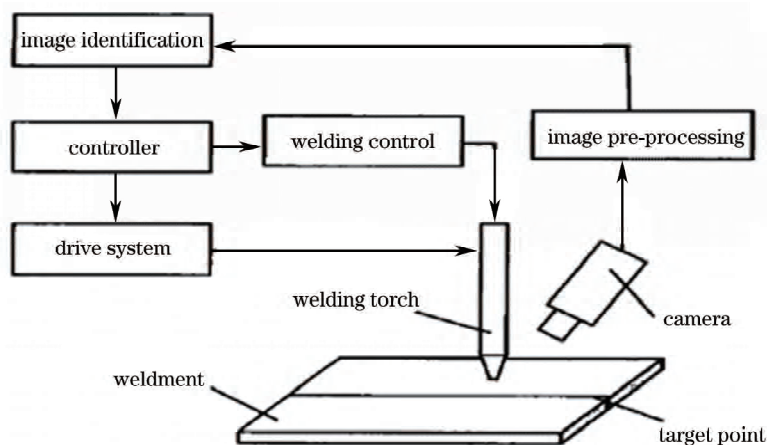


图 1 焊接识别系统^[9]

Fig. 1 Weld recognition system^[9]

为减少原始焊缝图像中存在的干扰,采用经典的中值滤波-灰度化-归一化方法对采集图像进行预处理,预处理后的图像特征更明显。凌超等^[13]认为中值滤波可以过滤图像中的噪声。灰度化将采集的三通道图片采用求均值的方法转为单通道的灰度图片。Alex-Networks^[3]采用归一化方法将灰度值范围为 $[0, 255]$ 的图像像素区间转为 $[-1, 1]$ 区间,从而能够更好地训练神经网络。

2.2 特征提取与目标识别

在卷积神经网络中,每个卷积层含有多个卷积核特征提取器,用于提取输入图像的特征。杨理践等^[14]将卷积神经网络应用于法兰焊缝识别中,并认为不同结构的卷积核具有边缘提取,锐化等功能。经每层的卷积核提取后的输出结果为该层的特征图,并作为下一个卷积层的输入。多层卷积层提取后输出的特征图为卷积网络对初始输入图像特征的

提取结果。将最后一个卷积层输出的特征图输入到全连接网络层,用于识别目标中心点坐标。识别目标的数量应与全连接网络层中的最后一层的输出节点数量相一致。通过训练整个网络的权值,最终使网络能够完成识别任务。

图 2 展示了采用 1 个 3×3 尺寸,步长为 1 的卷积核对于一幅 5×5 特征图两次卷积的计算过程。卷积核分别以 1 pixel 的步长与特征图对应区域像素做向量积,计算结果(图 2 中红色部分)输出下一层对应区域。对于传统卷积模块,当前层输出的特征矩阵为

$$Y = \text{Activef}(W \cdot X), \quad (1)$$

式中:Activef()表示激活函数; W 为网络权值; X 表示输入的特征矩阵。常见的激活函数有 RELU() 和 Sigmoid(),如图 3 所示。

池化层是用于缩减特征图尺寸的网络层,通常

分为最大池化层和平均池化层。最大池化层指区域内像素的最大值作为输出值。平均池化层指该区域的平均值作为输出值。刘帆等^[15]认为池化层可视为降采样过程,用于降低所提取的特征维度。




图2 卷积计算示意图

Fig. 2 Schematic of convolution calculation

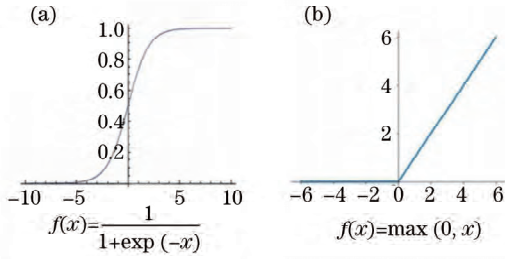


图3 激活函数图像。(a) Sigmoid; (b) RELU

Fig. 3 Activation function images. (a) Sigmoid; (b) RELU

2.3 基于同或卷积的压缩算法

考虑权值矩阵 W , 设其二值化后为 W_B , 下标 B 表示该矩阵被二值化, c_w 为权值矩阵的近似因子常量, 下标 w 表示该因子为权值矩阵的补偿因子, ΔH 为二者的距离, 即^[8]

$$\Delta H = \|W - c_w W_B\|^2 = W^T W + c_w^2 W_B^T W_B - 2c_w W^T W, \quad (2)$$

式中 W_B 的最优值 B^* 可表示为

$$B^* = \operatorname{argmax}\{W^T \cdot B\}, \quad (3)$$

式中 $\operatorname{argmax}\{\}$ 函数表示求取输入变量的最大值, 显然, B^* 的最优值为 W 的符号矩阵 B 。利用下式求解权值近似因子 c_w 最优值, r 与 c 分别为卷积核的长和宽的像素值。对于卷积核对应的特征图的像素矩阵, 对应的矩阵近似因子表示为

$$c_w = \frac{W^T B^*}{r \times c} = \frac{1}{r \times c} \|W\|_{11}, \quad (4)$$

$$c_1 = \frac{1}{r \times c} \|X\|_{11}. \quad (5)$$

联立(1)式、(4)式和(5)式, 可以得到卷积层和全连接层前向计算公式, 即

$$Y_B = \operatorname{Activef}[c_w c_1 \operatorname{sign}(X) \oplus \operatorname{sign}(W)], \quad (6)$$

式中 \oplus 表示同或运算, $\operatorname{sign}()$ 函数表示求取输入矩阵的符号矩阵。

2.4 权值压缩算法

同或卷积网络采用以像素值中值为阈值的二值化方法。这种方法虽然简单直接, 但是会对图像精度造成很大的损失, 以中值为阈值进行分割并不可靠。为更可靠地进行二值化压缩, 所提算法采用迭代方法确定阈值, 基于该阈值对权值进行二值化压缩。迭代方法的步骤为:

1) 计算卷积核的最大值和最小值, 分别记 $W_{\max 0}$ 与 $W_{\min 0}$, 取其平均值作为阈值, 即

$$T = \frac{W_{\max 0} + W_{\min 0}}{2}. \quad (7)$$

2) 根据当前的阈值 T 和各个卷积核的值, 将卷积核内部数据分为前景与背景两组。

3) 分别求出两组各自的平均值, 分别记为 $W_{\max 1}$ 与 $W_{\min 1}$, 求出新阈值为

$$T = \frac{W_{\max 1} + W_{\min 1}}{2}. \quad (8)$$

4) 循环步骤 2)~3), 直到两组的平均灰度值不再发生变化, 即获得了所需的阈值。

2.5 特征补偿算法

由(1)~(8)式可知, 卷积过程的输出近似于压缩前的输出, 下标 1 表示该因子是从特征图提取得出, 即

$$Y \approx c_w c_1 \operatorname{sign}(W) \oplus \operatorname{sign}(X). \quad (9)$$

由(9)式可知, 同或卷积过程可等效为无偏置的线性过程, 将浮点型因数的卷积操作转化为位运算, 可以极大地提高转化后模型的前向传播速度, 缩减模型空间。但是这样会减弱模型对输入的表示能力, 导致前向传播的测试精度偏差很大。对于一次的同或卷积过程, 加入补偿因子 C_0 , 即将(2)式修改为

$$\Delta H = \|W - c_w W_B\|_{12} + C_0 = \Delta H_1 + C_0. \quad (10)$$

将 ΔH_1 视为输入矩阵, 对其再次进行同或卷积, 则补偿因子可分离为

$$C_0 \approx c_{ww} \operatorname{sign}(W - c_w W_B), \quad (11)$$

式中 c_{ww} 为权值的二阶补偿因子, 双 w 下标为第二次对权值提取的线性补偿因子, 表示为

$$c_{ww} = \frac{\|W - c_w W_B\|_{11}}{r \times c}. \quad (12)$$

将(12)式代入(10)式可得

$$\Delta H = c_w W_B + c_{ww} W_{BB} + C_1 \approx c_w W_B + c_{ww} W_{BB}. \quad (13)$$

同理, 考虑输入矩阵 X , 则有

$$Y'_B = c_w W_B C_I X_I + c_{ww} W_{BB} C_{II} X_{II} + c_{ww} C_I W_{BB} X_I + c_w W_B C_{II} X_{II}, \quad (14)$$

式中 c_{II} 是输入特征图的二阶补偿因子, 由(5)式和(12)式可得到该因子的计算式, 表示为

$$c_{II} = \frac{\|W - c_I X_I\|_1}{r \times c}, \quad (15)$$

式中 c_w 与 c_{ww} 可在训练过程中得到, 并作为参数存储。可直接调取并参与测试过程, 无需重新计算。且每个卷积核仅增加一个参数, 对模型的存储空间影响极小。而 c_{II} 和 X_{II} 需要耗费计算量, 增加内存需求和模型尺寸。综合考虑计算量, 内存需求和模型尺寸的因素, 重新修正补偿参数, 则算法最终表述为

$$Y = (W \cdot B) \approx c_I c_w (W_B \oplus X_B) + c_{ww} c_I W_{BB} X_B. \quad (16)$$

训练完成后的模型由 32 bit 浮点数的权值和网络参数组成。所提算法将训练完成的模型权值压缩为 1 bit 的二进制数, 即将单精度浮点型卷积过程转为位运算的计算过程。损失的精度可由(16)式进行补偿, 从而实现对模型的压缩。与同或卷积网络不同, 所提算法采用迭代方法确定分割阈值, 并改进了特征补偿函数, 可以有效提高压缩后模型的精度。

3 结果分析

在 Inter(R) Core(TM) Duo-E7500 CPU, 内存 6 G, GTX1050 显卡上的 Linux 操作系统下进行仿真实验。首先说明标注过程和识别指标, 其次搭建深度卷积网络模型进行训练, 然后使用所提算法压缩模型, 最后在自制测试集上检验模型并分析模型

的性能指标。

3.1 数据采集、标注与数据集建立

使用大恒水星 MER-030-120UC 型号相机采集 50000 幅 V 形钢板焊缝图像, 如图 4 所示。为方便神经网络的训练, 以标记点为中心, 将每幅图片裁剪为 224 pixel × 224 pixel 尺寸的正方形图片。其中 40000 幅作为训练集, 10000 幅作为测试集。网络结构如图 5 和表 1 所示。表 1 中 $C_{64}(3 \times 3, S=1)$ 表示带有 64 个尺寸为 3×3 的卷积核, S 表示步长, RELU 和 Sigmoid 均表示激活函数, $P_{\max}(2 \times 2, S=2)$ 表示池化尺寸为 2×2 、步长为 2 的最大池化层, P_{avg} 表示平均池化层。




图 4 图像采集设备

Fig. 4 Image acquisition device

将采集到的图像样本进行标注, 标注内容为焊缝中心点的图像坐标。如图 6 所示, 采集的原始图像为 image_file。左侧图像中绿色交叉线为标记目标点, 其行坐标为 126(用 r_i 表示), 列坐标为 149(用 c_i 表示), 在图中用数字标出。再将行、列坐标存储于标签文件 label_file, 即完成对单幅图片的标注。




图 5 实验使用的卷积网络结构

Fig. 5 Convolution network structure used in experiments

表 1 网络结构及超参数列表

Table 1 Network structure and hyper-parameter list

Type of layers	Parameter
Convolution+activation function+pooling	$C_{64}(3 \times 3, S=1)+\text{RELU}+P_{\max}(2 \times 2, S=2)$
Convolution+activation function+pooling	$C_{128}(3 \times 3, S=1)+\text{RELU}+P_{\max}(2 \times 2, S=2)$
Convolution+activation function+pooling	$C_{256}(3 \times 3, S=1)+\text{RELU}+P_{\text{avg}}(2 \times 2, S=2)$
Convolution+activation function+pooling	$C_{512}(3 \times 3, S=1)+\text{RELU}+P_{\text{avg}}(2 \times 2, S=2)$
Convolution+activation function+pooling	$C_{512}(3 \times 3, S=1)+\text{RELU}+P_{\text{avg}}(2 \times 2, S=2)$
Full connction+activation function	400 neutral units+RELU
Full connction+activation function	400 neutral units+RELU
Loss function	Euclidean distance




图 6 工件 1 的标注

Fig. 6 Making labels for weldment 1

如图 7 所示,本次实验采用修正的 Alexnet 进行实验。损失函数以预测点与标签点坐标的欧氏距离计算。设预测点与标签点的像素坐标分别为 (r_p, c_p) 和 (r_t, c_t) ,则损失函数 d 表示为

$$d = \sqrt{(r_p - r_t)^2 + (c_p - c_t)^2}. \quad (17)$$

模型预测的坐标点应在焊缝范围内,且与标记点的距离越小,模型精度越高。而在实际情况下允许焊枪与焊件相接处是一个接近圆形的区域。根据焊枪尺寸和实际的焊接实验,以标记点为圆心,半径 10 pixel 区域内可以完成焊接工作。超出该区域则认为预测错误。设 i 为记数变量,准确率 Q 可表示为

$$Q = \frac{\sum_i^N \text{signtest}(d)}{N}, \quad (18)$$

式中: d 为测试过程中预测点与标记点欧氏距离,其计算方法与(17)式的损失函数值的计算方法相同;

表 2 模型大小与内存需求

Table 2 Model size and memory requirements

Without compression		After compression		Compression ratio	Speed ratio	Loss / %
Maximum memory requirement / MB	Model size / MB	Maximum memory requirement / MB	Model size / MB			
38	55.3	1.1	2.33	23.8	26.3	1.4

N 为测试样本总数;signtest()为判定函数,当预测结果超过允许范围函数结果为 0,在区域内结果为 1,即

$$\text{signtest}() = \begin{cases} 1, & d \leq 10 \\ 0, & d > 10 \end{cases} \quad (19)$$




图 7 计算结果

Fig. 7 Computing result

3.2 模型压缩及性能分析

训练 40000 轮并分析模型性能。其中最大内存需求表示各层中消耗内存最多的层所需的内存量。模型需求即为压缩后的模型大小。如表 2 所示,所提算法对模型达到 1/23.8 的压缩比率,极大地压缩了模型的尺寸。相比于 Alex 提出的原网络结构模型,压缩后的模型也具有很好的加速功能。此外,图 8 对比了未压缩模型、传统算法压缩模型和经所提算法压缩后的模型识别率。可以看到,经改进后的压缩算法识别率提高了 8.7%,与原未压缩模型的识别率基本一致,说明所提算法改善了原压缩算法精度低的问题。




图8 模型识别率对比

Fig. 8 Recognition rate comparison among models

3.3 性能对比

3.3.1 单类工件预测

采用常见的几种焊缝分析算法输入测试集并进行测试,将计算结果与所提算法(GXN)得出的模型进行对比。其中常用的方法有高斯滤波+SIFT特征点提取算法(GS)、加速稳健特征点提取算法(SURF)、Harries角点检测方法(HC)、最小二乘法拟合直线法(LSE)、高斯滤波+Hough拟合法(GH)。按照3.1节中所述指标评价算法的准确率。

计算结果如表3所示,可以看出,所提算法准确率高于其他算法。由于传统算法在外界环境相对固定的条件下(通常是暗室或人工改变外界光照条件),其图像几何结构相对固定,故可以通过简单的提取特征点和几何关系来确定目标点。但是该类方法稳定性较差,必须增加成本对视觉感光设备进行精确配合,且一旦工作环境与初始设定的模型稍有变化则需要重新建模、调整和校正。而深度神经网络模型能够提取图形的高维非线性特征,稳定性好,不易受外界局部条件的干扰。

表3 工件1的测试准确率

Table 3 Test accuracy of weldment 1

Method	Accuracy / %
GS	94.3
SURF	92.4
HC	90.1
LSE	87.6
GH	93.3
GXN	97.5

3.3.2 混合工件预测

采集第二种工件的图像(图9)并进行标注,采集数量和标注方法与3.1节相同。制成新的数据集(图10),重新加载未压缩的深度神经网络模型并进行训练。训练完成后将模型在新的测试集上按照

3.3.1节方法进行测试,并验证算法。新的测试集由两种工件中各提取5000幅组成。



图9 第二种工件

Fig. 9 Second weldment



图10 焊接点标签

Fig. 10 Label of weldment point

由图11和表4可知,在两种工件混合的情况下,各算法精度均有所下降,但是深度卷积网络模型指标基本维持原准确率。而其他算法由于新工件与原工件几何关系不同导致识别准确率大幅下降。表5列出了各算法完成识别任务所消耗的平均时间。可以看出,压缩后的深度卷积模型识别速度与其他算法耗费时间相近,与未压缩的模型相比极大地提高了计算速度,具有很好的时效性。综上所述,经所提算法压缩后的深度卷积网络模型具有很好的抗干扰能力,准确率比传统算法高,且具有多目标识别能力。

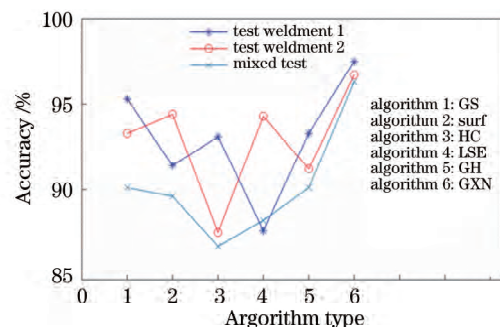


图11 混合测试结果折线图

Fig. 11 Polygon diagram of mixed test results

表4 多工件的测试结果

Table 4 Test results of multiple weldments

Method	Accuracy /%	
	Second	Mixed
	weldment test	data test
GS	93.3	90.1
SURF	94.4	89.6
HC	87.5	86.7
LSE	94.3	88.2
GH	91.2	90.1
GXN	96.7	96.3

表5 各种算法的时效性

Table 5 Time consumption of each method

Method	Time /ms
GS	35
SURF	27
HC	17
LSE	39
GH	37
GXN	36

4 结 论

基于视觉传感的焊缝跟踪技术重点是图像处理,而传统的图像分割-特征点特区-几何关系分析的方法易受多种干扰,且难以扩展应用范围。所使用的深度卷积网络模型和改进后的压缩算法可以准确定位目标中心位置,减小焊缝识别的错误率。实验结果表明,所提算法能够有效压缩深度卷积网络模型,并维持原模型高精度的特点。且相比于传统算法,压缩后模型的识别率更高,稳定性更好,更适合工业生产。

参 考 文 献

- [1] Lowe D G. Distinctive image features from scale-invariant keypoints [J]. International Journal of Computer Vision, 2004, 60(2): 91-110.
- [2] Zhang G G. Summary of corner detection technology [J]. Digital Technology and Applications, 2013, (4): 157.
张功国. 角点检测技术综述[J]. 数字技术与应用, 2013, (4): 157.
- [3] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks [C] // Advances in Neural Information Processing Systems, 2012: 1097-1105.
- [4] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv: 1409.1556, 2014.
- [5] Zhou Z H. Machine learning [M]. 1st ed. Beijing: Tsinghua University Press, 2016: 213-215.
周志华. 机器学习[M]. 1 版. 北京: 清华大学出版社, 2016: 213-215.
- [6] Han S, Mao H Z, Dally W J. Deep compression: compressing deep neural networks with pruning, trained quantization and huffman coding[J]. Fiber, 2015, 56(4): 3-7.
- [7] Hubara I, Courbariaux M, Soudry D, *et al*. Binarized neural networks [C] // Advances in Neural Information Processing Systems, 2016: 4107-4115.
- [8] Rastegari M, Ordonez V, Redmon J, *et al*. XNOR-Net: ImageNet classification using binary convolutional neural networks [C] // European Conference on Computer Vision, 2016: 525-542.
- [9] Sun W X. A weld seam recognition and tracking system of welding robot based on machine vision[D]. Qingdao: Qingdao University of Science & Technology, 2018: 13-17.
孙文侠. 基于机器视觉的焊接机器人焊缝识别与跟踪系统[D]. 青岛: 青岛科技大学, 2018: 13-17.
- [10] Fan D J, Yang L X, Ding L, *et al*. Weld line extraction based on improved least square method[J]. Hot Working Technology, 2018, 47(15): 217-220, 224.
樊德金, 杨龙兴, 丁力, 等. 基于改进最小二乘法的焊缝直线提取研究[J]. 热加工工艺, 2018, 47(15): 217-220, 224.
- [11] Zhou H M, Lu J F, Lü J S, *et al*. Research on weld defect type recognition method based on multi-scale texture features[J]. Electromechanical Technology, 2018(3): 14-16.
周红明, 卢建飞, 吕建森, 等. 基于多尺度纹理特征的焊缝缺陷类型识别方法研究[J]. 机电技术, 2018 (3): 14-16.
- [12] Xu H. Weld identification and trajectory planning based on machine vision [D]. Nanning: Guangxi University, 2017.
许皓. 基于机器视觉的焊缝识别及轨迹规划[D]. 南宁: 广西大学, 2017.
- [13] Ling C, Ji B J, Hong L, *et al*. An algorithm for automatic recognition of V shape weld guided by laser vision [J]. Modular Machine Tool and Automatic Machining Technology, 2017(6): 9-12, 17.
凌超, 嵇保健, 洪磊, 等. 一种激光视觉引导的自动识别 V 形焊缝的算法[J]. 组合机床与自动化加工技术, 2017(6): 9-12, 17.

- [14] Yang L J, Cao H. Deep learning based weld and flange identification in pipeline[J]. Chinese Journal of Scientific Instrument, 2018, 39(2): 193-202.
杨理践, 曹辉. 基于深度学习的管道焊缝法兰组件识别方法[J]. 仪器仪表学报, 2018, 39(2): 193-202.
- [15] Liu F, Liu P Y, Li B, *et al.* Deep learning model design of video target tracking based on TensorFlow platform [J]. Laser & Optoelectronics Progress, 2017, 54(9): 091501.
刘帆, 刘鹏远, 李兵, 等. TensorFlow 平台下的视频目标跟踪深度学习模型设计[J]. 激光与光电子学进展, 2017, 54(9): 091501.